การบ้าน PySpark (version 4.2.0)

Problems

โครงสร้างข้อมูล

ข้อมูลที่จะใช้ในข้อนี้จะเป็นข้อมูล Youtube Trending ซึ่งแต่ละ Row จะเป็น Video และประกอบไปด้วย Column ต่อไปนี้

video_id	Unique YouTube video identifier
trending_date	Trending snapshot date token (YY.DD.MM)
title	Video title at collection time
channel_title	Channel display title
views	View count at collection time
likes	Like count at collection time
dislikes	Dislike value (official when available, otherwise backfilled estimate)
publish_time	Original publish timestamp (ISO 8601)
category_id	YouTube category identifier
tags	Video tags joined by |
comments	Comment count at collection time
channel_id	YouTube channel identifier
description	Video description text

q1 Function: จงเขียน q1(df) เพื่อทำการนับจำนวน video ใน df โดยที่

- df คือ Spark SQL Dataframe ที่สร้างจากการอ่านข้อมูล Youtube Trending
- Output: จำนวน video (หรือจำนวน row) ที่มีใน df (int) เช่น 13579

q2 Function: จงเขียน q2(df) เพื่อหา video_id ของ video ที่มีการ comments มากที่สุด โดยที่

- df คือ Spark SQL Dataframe ที่สร้างจากการอ่านข้อมูล Youtube Trending
- ฟังก์ชันต้องทำการหา video ที่มี comments มากที่สุด
- Output: video_id ของ video ที่มีการ comments มากที่สุด (string) เช่น g3zTR0_n-YY

q3 Function: จงเขียน q3(df) เพื่อทำการหา category ที่มีจำนวน video มากที่สุด โดยที่

- df คือ Spark SQL Dataframe ที่สร้างจากการอ่านข้อมูล Youtube Trending
- ฟังก์ชันต้องทำการนับจำนวน video แยกตาม category
- Output: category_id ของ category ที่มีจำนวน video มากที่สุด (int) เช่น 20

q4 Function: จงเขียน q4(df) เพื่อทำการหา video ที่มีค่า like_ratio ที่มากที่สุด โดยที่

- df คือ Spark SQL Dataframe ที่สร้างจากการอ่านข้อมูล Youtube Trending
- ค่า like_ratio จะเป็นค่าที่ถูกคำนวณของแต่ละ video โดยที่ like_ratio = likes / views
- ไม่ต้องนำ video ที่มี views เป็น 0 มาคำนวณ like_ratior
  (grader ใช้ Spark 4 ซึ่งการหารด้วย 0 จะเกิด error)
- ฟังก์ชันต้องทำการคำนวณค่า like_ratio ของแต่ละ video แล้วหาค่า like_ratio ที่มากที่สุด
- Output: ค่า like_ratio ที่มากที่สุด (float) เช่น 1258.8

Expected Results

Code	Output
print(q1(df))	13579
print(q2(df))	g3zTR0_n-YY
print(q3(df))	20
print(q4(df))	1258.8

หมายเหตุ: grader จะตรวจคำตอบด้วยข้อมูลชุดอื่นเพิ่มเติมนอกเหนือจาก youtube_trending.csv ดังนั้นห้ามใส่คำตอบตายตัวลงในโค้ด

Attached Files

File	Description
student.py	Template code เพื่อใช้ในการตอบคำถาม และ submit เข้า grader
youtube_trending.csv	ไฟล์ข้อมูลเพื่อใช้ในการทดลองระหว่างการพัฒนา